Atoms

各位面试官好，感谢阅读这个项目。

我把 Atoms 做成了一个可以直接体验的 MVP：用户用自然语言描述想做的应用，Engineer Agent 在隔离 workspace 里生成前端、后端代码，系统再用 Docker sandbox 启动预览。

在线体验：https://jackybigwang.site

测试账号：

```
邮箱：test@atoms.demo
密码：test1234
```

为了节省您的时间，这个测试账号里已经有生成好的项目，可以直接打开项目、查看文件、查看 Agent 对话和预览结果。 您也可以自己注册账号，创建workspace进行完整体验～

项目定位

- 用户可以登录并管理自己的项目。
- 用户可以和 Engineer Agent 对话，让它生成或修改应用。
- Agent 会先给出 plan，用户 approve 后再写代码。
- 生成代码会落到项目 workspace，并持久化到数据库。
- 每个项目在独立 Docker 容器里启动 preview。
- preview 启动前会经过 health check 和 smoke check，尽量把不可运行的结果挡在预览前。

整体架构

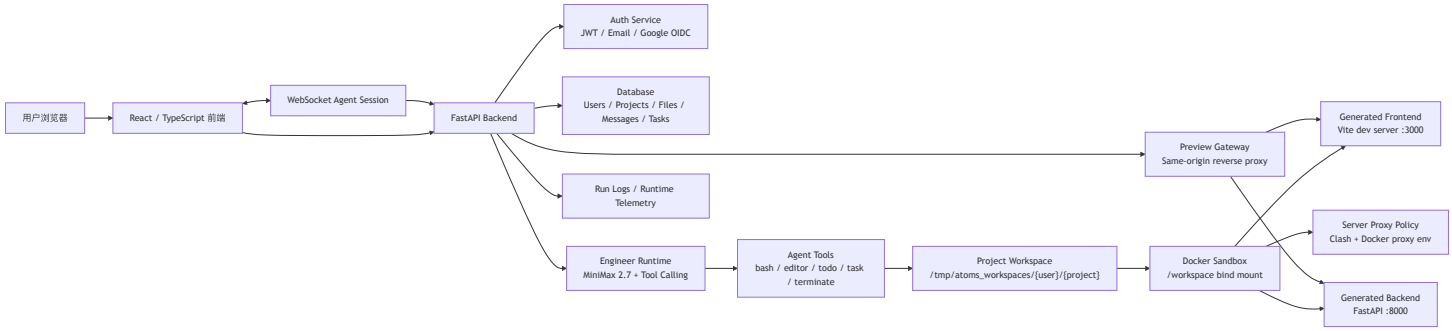

Workflow

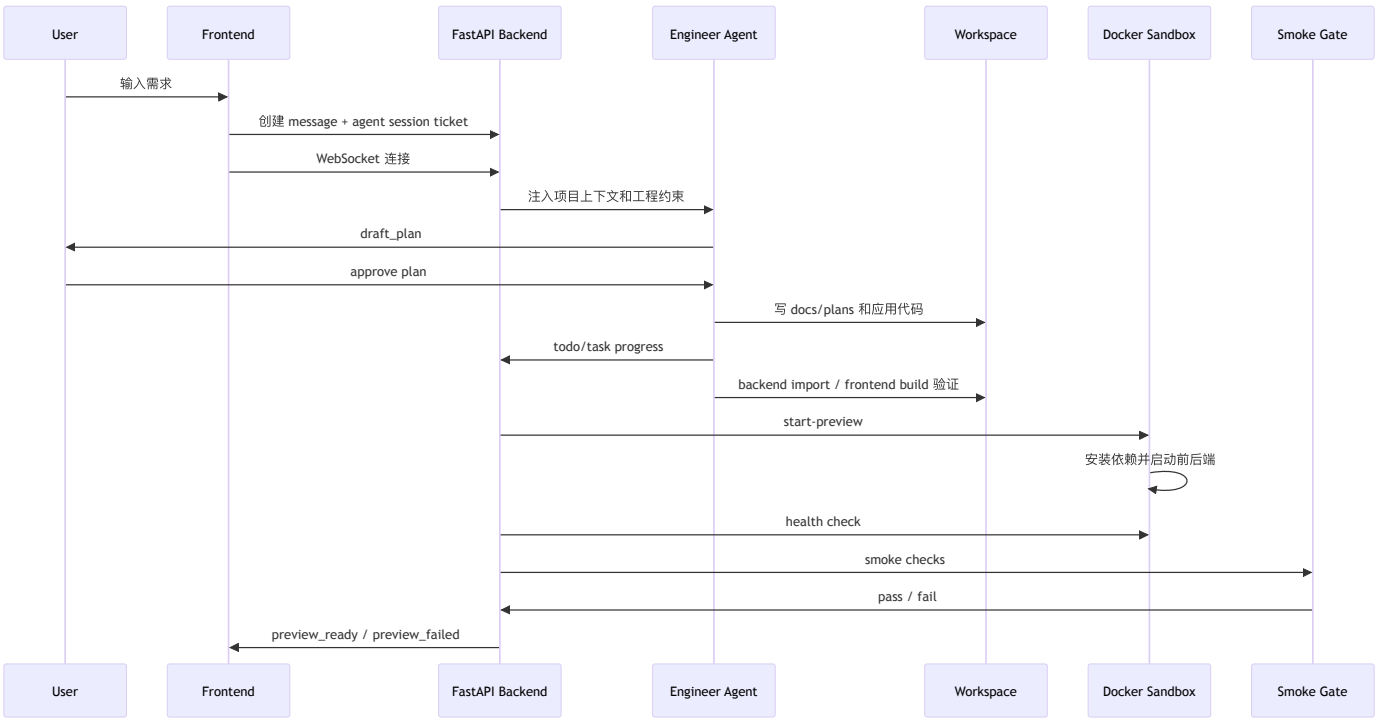

设计idea overview

1. 产品层：React 前端负责项目管理、对话、文件树、preview iframe 和实时状态展示。
2. 控制层：FastAPI 后端负责鉴权、持久化、Agent runtime、preview session、smoke gate 和 telemetry。
3. 执行层：Docker sandbox 负责真正运行用户生成的代码，和主系统隔离。

这样做的好处是：用户数据由后端统一保护，LLM 的写文件和跑命令被限制在 workspace 里，生成应用的依赖和进程被限制在 Docker 里，preview 也不直接暴露随机端口，而是通过后端发放的 session key 走同源反向代理。

技术栈

模块	技术选型
前端	React 18, TypeScript, Vite, Tailwind CSS, Radix UI, Monaco Editor
后端	FastAPI, SQLAlchemy async, Pydantic v2
数据库	SQLite 本地开发，PostgreSQL 生产可切换
认证	JWT, bcrypt, Google OIDC, Resend Email

模块	技术选型
LLM Runtime	OpenAI-compatible client, MiniMax-M2.7-highspeed, tool calling
Agent 工具	bash, str_replace_editor, draft_plan, todo_write, task_update, load_skill, terminate
沙箱	Docker, Node 20, Python 3, pnpm, uv
Preview	start-preview, health check, smoke gate, same-origin preview gateway
运维	systemd, Nginx, Clash proxy policy, Docker build proxy

登录功能实现

登录系统主要代码在：

- `app/backend/models/auth.py`
- `app/backend/services/auth.py`
- `app/backend/services/email_service.py`
- `app/backend/routers/auth.py`
- `app/frontend/src/contexts/AuthContext.tsx`
- `app/frontend/src/lib/auth.ts`

邮箱注册和常规登录

邮箱注册使用 email/password 模式：

1. 用户提交邮箱、密码和昵称。
2. 后端使用 bcrypt 对密码做 hash，不保存明文密码。
3. 用户 ID 使用 `email|{uuid}` 格式，和 OIDC 用户区分。
4. 新用户默认 `is_verified=false` 。
5. 系统创建 `EmailVerificationToken` ，有效期 24 小时。
6. `EmailService` 通过 Resend 发送验证邮件。
7. 用户点击验证链接后，后端把用户标记为已验证。
8. 常规登录时，后端会校验密码和 `is_verified` ，通过后签发应用自己的 JWT。

忘记密码走类似流程：创建 `PasswordResetToken` ，有效期 1 小时，使用后标记为 used，避免重复使用。

Google 登录

Google 登录使用标准 OIDC Authorization Code + PKCE 流程：

1. 前端点击 Google 登录后跳转到 `/api/v1/auth/login` 。
2. 后端生成 `state` 、 `nonce` 、 `code_verifier` 和 `code_challenge` 。
3. 这些临时值存在 `oidc_states` 表里，防止 CSRF 和 nonce replay。
4. 用户在 Google 完成授权后，Google 回调 `/api/v1/auth/callback` 。
5. 后端用 code 换 token，并通过 Google JWKS 校验 ID token。
6. 校验 issuer、audience、nonce、过期时间和签名。
7. 后端通过 Google sub 查找或创建用户。
8. 最后签发 Atoms 自己的 JWT，并 redirect 到前端 callback 页面。

前端拿到 JWT 后存到 `localStorage` ，后续 API 请求通过 `Authorization: Bearer <token>` 鉴权。

国内网络和稳定性

因为服务器访问 Google、GitHub、npm、PyPI、模型 API 都可能受网络影响，我在服务器侧做了统一代理策略：

- 服务器出站走 Clash mixed port。
- 只选择新加坡、日本、台湾、美国、韩国的非直连稳定节点。
- 去掉直连节点、香港节点和不相关节点。
- Clash 的 Auto group 用 `url-test` 自动选择延迟最低节点。
- `tolerance` 设置为 `500ms` ，只要当前节点延迟不高于 500ms 就不频繁切换，优先稳定性。
- Docker daemon、sandbox build、git fetch、sandbox runtime 都显式接入代理环境变量。

这部分脚本和说明在：

- `scripts/configure-server-clash-policy.sh`
- `scripts/build-atoms-sandbox.sh`
- `docs/server-operations.md`

LLM runtime 里也有一个小的稳定性处理：tokenizer 优先使用 `tiktoken` ，如果因为网络或包数据问题不可用，会退回到本地字符估算，避免因为 tokenizer 下载失败导致 Agent 不能工作。

LLM Runtime 设计

核心代码位置：

- `app/backend/openmanus_runtime/llm.py`

- `app/backend/openmanus_runtime/agent/base.py`
- `app/backend/openmanus_runtime/agent/toolcall.py`
- `app/backend/openmanus_runtime/streaming.py`
- `app/backend/openmanus_runtime/tool/`
- `app/backend/services/engineer_runtime.py`
- `app/backend/services/approval_gate.py`
- `app/backend/services/agent_task_store.py`
- `app/backend/services/runtime_telemetry.py`

1. 大模型接入

Atoms 使用 OpenAI-compatible client 接入大模型，默认配置是 MiniMax 2.7：

```
APP_AI_BASE_URL=https://api.minimax.chat/v1
APP_AI_DEFAULT_MODEL=MiniMax-M2.7-highspeed
APP_AI_KEY=your-minimax-api-key
```

`openmanus_runtime/llm.py` 封装了模型调用：

- 普通文本调用： `ask`
- 图文调用： `ask_with_images`
- 工具调用： `ask_tool`

工具调用使用非 streaming 请求，因为模型需要一次性返回完整 `tool_calls` 。前端看到的“流式体验”由 runtime 把 assistant message、progress、terminal log、task update 等事件通过 WebSocket 推送出来。

模型错误处理也做了区分：例如 429、408、409 可以 retry；明显的 400 bad request 不会盲目重试，而是交给 runtime 判断是否能自愈。

2. 工具选择和工具设计

工具	用途
`draft_plan`	先生成 3-7 项计划，并等待用户 approve
`str_replace_editor`	查看、创建、替换、插入 workspace 内文件
`bash`	在 sandbox/workspace 上下文里运行命令
`todo_write`	初始化 Agent checklist

工具	用途
`task_update`	更新任务状态
`load_skill`	按需加载技能说明
`terminate`	明确结束本轮任务

工具层做了几类工程限制：

- 写文件必须在 `/workspace` 内，不能逃逸到宿主机路径。
- `bash` 会拦截高风险 inline 写文件方式，要求通过 editor 工具改文件。
- 常见安装命令会被 rewrite 到 `atoms-deps-cache` ，避免每次 preview 都重新安装依赖。
- `todo_write` 最多 8 个任务，且同时只能有一个 `in_progress` 。
- blocked task 不能被直接标记为进行中或完成。
- 静默工具不会刷屏到前端，但会更新任务、进度和 telemetry。

这个设计的目标是让 Agent 仍然有足够自由度完成真实工程任务，但不能无限制地写文件、乱跑命令或绕过用户 approve。

3. Prompt 位置和设计原因

Prompt 分两层。

第一层是基础 SWE prompt：

- `app/backend/openmanus_runtime/prompt/swe.py`

它定义 Agent 是命令行环境里的软件工程师，必须使用工具查看和修改文件，避免假装完成。

第二层是项目级动态 prompt：

- `app/backend/services/engineer_runtime.py`

这里会把当前 project、workspace 约束、preview contract、生成规范、验证命令和 workflow 一起注入给 Agent。重要约束包括：

- 必须在 `/workspace` 下工作。
- 必须先调用 `draft_plan` ，等待用户 approve。
- approve 后必须写详细计划到 `docs/plans/{YYYY-MM-DD}-{feature}.md` 。
- React 前端调用后端时不能写死 localhost，必须使用 `VITE_ATOMS_PREVIEW_BACKEND_BASE` 。
- 如果生成 backend，必须提供 `/health` 。
- 如果 backend 有 `/health` 之外的 API route，必须创建 `.atoms/smoke.json` 。

- PNG 接口 smoke 必须检查 `content_type=image/png` 和 PNG base64 prefix `iVBORw0KGgo=` 。
- Backend import 验证必须使用 runtime 指定命令，避免路径和 venv 不一致。

这个 prompt 的设计思路是：不要只告诉 LLM “你要写好代码”，而是把平台运行时的硬性契约写进任务说明里，让 Agent 生成的代码更容易被 Docker preview 和 smoke gate 接住。

4. Memory 设计

Atoms 目前有三类 memory：

1. 对话和项目文件的持久化 memory。
    - `messages` 表保存用户和 assistant 消息。
    - `project_files` 表保存项目文件快照。
    - 项目再次打开时，可以恢复对话、文件树和上下文。
2. 单次 Agent run 的短期 memory。
    - `openmanus_runtime/schema.py` 里的 `Memory` 保存本轮消息。
    - ToolCallAgent 根据这些消息决定下一步工具调用。
3. 工程任务 memory。
    - `agent_tasks` 保存 checklist/task 状态。
    - run logs 保存 `latest.json` 、 `latest.jsonl` 和 `latest_metrics.jsonl` 。
    - telemetry 记录 bash、dependency、preview、smoke、verification 等事件。

5. 自动 compact 策略

长任务会导致上下文膨胀，runtime 里做了两层 compact：

1. micro compact
    - 保留最近几个 tool 结果。
    - 旧的长 tool output 会被替换成短摘要，例如“之前使用过某工具”。
    - 对 `read_file` / `view_file` 这类关键文件读取结果更保守，避免丢掉工程上下文。
2. auto compact
    - 当估算 token 超过约 50k 时触发。
    - 保留第一条任务消息和最近几条消息。
    - 中间历史交给 LLM 总结成 compact summary。
    - summary 要覆盖已完成工作、当前状态、关键决策、剩余任务和用户约束。

这不是为了节省 token 而随便裁剪，而是为了在长任务里保留“现在做到哪、为什么这么做、下一步是什么”。

6. Task system 如何防止 Agent 偷懒

Atoms 对 Agent 的约束不是只靠 prompt，而是靠 runtime gate：

- 没有 `draft_plan` approval，写操作会被 `approval_gate` 拦截。
- approve 后还必须写 `docs/plans/*.md`，否则实现阶段写操作仍然会被拦。
- `todo_write` / `task_update` 把任务状态落库，前端实时展示 checklist。
- 同一时间只能有一个任务 `in_progress`，减少“全部标完成”的假进度。
- backend import check 会在完成前重新跑；失败会把错误反馈给 Agent 修复。
- preview 会先跑 health check。
- 如果 backend 暴露业务 API，必须有 `.atoms/smoke.json`，并且 smoke 失败会 fail closed。
- 工具调用 JSON 出错时，runtime 会把明确错误喂回同一个 Agent，让它自修，而不是简单 retry 或直接失败。

所以这里的策略是：Prompt 负责告诉 Agent 怎么做，工具和 gate 负责强制它按工程流程做。

数据持久化和隔离

数据库持久化

后端使用 SQLAlchemy async，开发环境可以用 SQLite，生产环境可以切到 PostgreSQL。主要持久化对象包括：

- `users`
- `user_profiles`
- `projects`
- `project_files`
- `messages`
- `agent_tasks`
- `workspace_runtime_sessions`
- `email_verification_tokens`
- `password_reset_tokens`
- `oidc_states`

每个项目的文件会在数据库里保存一份，同时 materialize 到宿主机 workspace 目录，供 Docker sandbox bind mount 使用。

账号数据隔离

主路径 API 都依赖 `get_current_user` 解析 JWT，并且用 `user_id` 过滤数据：

- 项目列表只查当前用户项目。
- 项目详情要求 `project.user_id == current_user.id` 。
- 文件、消息和任务都带 `user_id` / `project_id` 。
- `projects` 表对 `(user_id, project_number)` 做唯一约束，保证不同用户可以有自己的项目编号空间。

项目 workspace 路径也是按用户和项目隔离：

```
/tmp/atoms_workspaces/{user_id}/{project_id}
```

Docker 容器按项目创建，并把这个目录挂载为：

```
/workspace
```

这样 Agent 和 generated app 只能看到当前项目 workspace。

Docker sandbox 设计

每个项目有独立容器，使用同一个 `atoms-sandbox:latest` 镜像：

- 镜像内置 Node 20、Python 3、pnpm、uv 和常用 Python 包。
- 容器启动后保持 `sleep infinity` ，preview 时再 exec `start-preview` 。
- 前端默认运行在容器内 3000 端口。
- 后端默认运行在容器内 8000 端口。
- 宿主机用随机端口映射，避免项目之间冲突。
- 后端通过 Docker API 获取映射端口，再发放 preview session。
- 用户访问的是 `/preview/{session_key}/frontend/` 和 `/preview/{session_key}/backend/` ，不是直接访问容器端口。

依赖安装通过 `atoms-deps-cache` 做缓存：

- 前端根据 `package.json` 、lockfile hash 判断是否复用 `node_modules` 。
- 后端根据 `requirements.txt` 、 `pyproject.toml` 、 `uv.lock` hash 判断是否复用 `.venv` 。
- Agent 在 bash 里常见的 `pnpm install` 、 `uv pip install` 也会被 rewrite 到这个 wrapper。

Preview 和 Smoke Gate

生成项目必须提供 `.atoms/preview.json` ，告诉平台如何启动前端和后端。 `start-preview` 读取这个文件后：

1. 安装或复用前端依赖。
2. 安装或复用后端依赖。
3. 注入 `ATOMS_PREVIEW_FRONTEND_BASE` 、 `ATOMS_PREVIEW_BACKEND_BASE` 、 `VITE_ATOMS_PREVIEW_BACKEND_BASE` 。
4. 启动前端 dev server。
5. 启动后端 server。
6. 后端 runtime 等待 health check。
7. 如果需要，运行 `.atoms/smoke.json` 。
8. 全部通过后发送 `preview_ready` 。

Smoke gate 的规则比较严格：

- 如果 backend OpenAPI 里发现 `/health` 以外的业务 API，就要求 workspace 里存在 `.atoms/smoke.json` 。
- OpenAPI 解析失败、非 200、schema 异常都会 fail closed。
- PNG 响应可以检查 `content_type=image/png` 和 body base64 prefix。
- smoke 失败时不会把 preview 当成成功。

这是为了避免“页面看起来启动了，但核心 API 根本不能用”的情况。

当前 MVP 的边界

Atoms 已经跑通了从登录、项目管理、Agent 编码、Docker preview 到 smoke gate 的主链路，但它仍然是 MVP。

我会特别说明一个工程边界：主业务 API 已按 `current_user` 做了用户隔离，但代码库里还有一些早期生成的通用 CRUD `/all` 类接口，需要在下一阶段收紧或下线。面试场景下我更希望把这个问题明确暴露出来，而不是假装它不存在。

未来可以提升的点

1. 用 templates / skills 提升生成稳定性

完全依赖 Agent 从零生成前后端，稳定性不够。更好的方式是由系统分发稳定模板，例如：

- React + Vite 基础模板
- FastAPI 基础模板
- preview contract 模板

- smoke contract 模板
- 常见登录、表单、图表、文件上传模块

Agent 只负责生成真正有创造性的业务部分。模板化代码由系统直接落盘，可以显著降低 one-shot 失败率。

2. 实现真正的 Agent teams

目前系统里主要是 Engineer Agent。后续可以加一个 Leader / Orchestrator：

- Leader 负责理解需求、拆任务、决定是否需要前端、后端、测试、设计等角色。
- Engineer 负责编码。
- Reviewer 负责检查 contract、测试和安全问题。
- Debugger 负责根据 runtime error 做定向修复。

这样可以从“一个 Agent 完成所有事”升级为“多角色协作完成复杂工程”。

3. 做系统化 eval 和安全收敛

现在 smoke gate 已经能挡住一部分运行时问题，但还不够系统。下一步我会做：

- 固定 benchmark prompts，覆盖 CRUD、图像生成、文件上传、图表、后端 API 等场景。
- 每次 runtime/prompt 改动后自动跑生成质量回归。
- 把 preview failure、smoke failure、tool JSON error、dependency install error 结构化入库。
- 用统计结果反推 prompt、模板、工具和 sandbox 的改动。
- 收紧 legacy `/all` 接口和 admin-like endpoint，保证所有数据访问都有明确权限边界。

这一步能把 Agent 平台从“看起来能跑”推进到“可持续迭代、可衡量质量”。

总结

Atoms 这个 MVP 想展示的是一个完整闭环：用户提出需求，Agent 规划并编码，系统隔离运行，preview 和 smoke gate 验证结果，所有过程实时可见并可追踪。

我没有把重点放在做更多页面功能，而是放在应用生成平台最关键的工程问题上：鉴权、隔离、工具约束、长上下文、任务推进、依赖安装、preview、smoke、自愈和 telemetry。